COÛTS ÉCOLOGIQUES DE L'INTELLIGENCE ARTIFICIELLE

Catherine Breslin & Team and Adobe Firefly / Better Images of AI / Chipping Silicon / CC-BY 4.0

L'IA consomme de l'énergie, de l'eau et des métaux. Ses émissions de gaz à effet de serre dépendent de l'électricité (nucléaire, charbon, renouvelables). Les centres de données consomment de l'eau pour se refroidir. Leur construction bétonne des terres naturelles ou agricoles.

ALLER PLUS LOIN

Les émissions de gaz à effet de serre du numérique augmentent actuellement de 6% par an au niveau mondial, une trajectoire incompatible avec les Accords de Paris sur le climat. Dans la course à l'IA, les géants de la tech ont abandonné leurs promesses de réduction des émissions. Par exemple, Google a augmenté ses émissions de 48 % entre 2019 et 2024, et Microsoft de 29 % entre 2020 et 2023.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

CONSOMMATION EN ÉLECTRICITÉ ET EN EAU DES DATA CENTERS

Kathryn Conrad & Rose Willis / Better Images of AI / Extraction Network 1 / CC-BY 4.0

Les centres de données consomment eau et électricité en continu pour alimenter et refroidir leurs machines. Entraîner un modèle comme Mistral Large 2 a consommé 281 000 m^3 d'eau en 18 mois. Ce n'est pas une requête seule qui pèse, mais leur cumul : ChatGPT traite 2,5 milliards de messages par jour.

ALLER PLUS LOIN

PAR08, un grand centre de données à La Courneuve, près de Paris, consomme 248 000 m^3 d'eau potable/an (environ 100 piscines olympiques) selon un rapport de 2023 de la DREAL Île-de-France. Cette eau est pompée dans le réseau de Saint-Denis, une zone touchée par des sécheresses répétées depuis 2003. Le rapport souligne l'absence de plan de réduction de la consommation en cas de pénurie d'eau.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

EXTRACTION DE MINERAIS POUR FABRIQUER LES PUCES ÉLECTRONIQUES

Luke Conroy and Anne Fehres & AI4Media / Better Images of AI / Models Built From Fossils / CC-BY 4.0

Faire tourner une IA à grande échelle demande des millions de puces électroniques. Pour les fabriquer, il faut des minerais comme le silicium, le gallium ou le cobalt. Les extraire, les transporter et les traiter consomme de l'énergie et de l'eau, et produit des déchets toxiques.

ALLER PLUS LOIN

En décembre 2024, la Chine a interdit l'exportation de gallium vers les États-Unis, un minerai indispensable aux puces électroniques des centres de données. La Chine en produit 98% à l'échelle mondiale. Elle a suspendu cette interdiction en novembre 2025, lors d'une trêve commerciale avec les États-Unis.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

OPACITÉ DE L'IMPACT ÉCOLOGIQUE DE L'IA

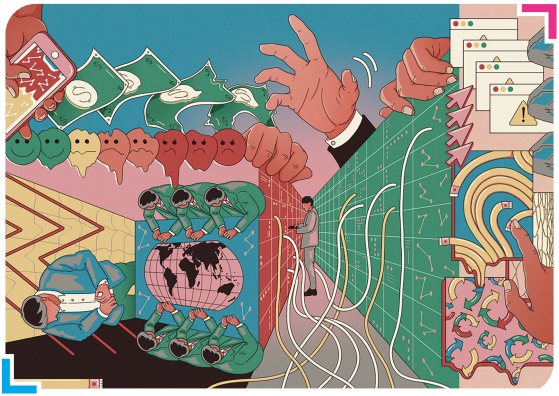

Clarote & AI4Media / Better Images of AI / Power/Profit / CC-BY 4.0

L'impact écologique de l'IA est difficile à mesurer, faute de données. Les grandes entreprises cachent volontairement ce qu'elles consomment en eau, en énergie et émettent en CO_2. Ce silence empêche les États de réguler cette industrie, et chacun de mesurer l'effet de ses usages.

★★

ALLER PLUS LOIN

En juillet 2025, Mistral AI a publié un bilan environnemental de son modèle Large 2, avec le soutien de l'ADEME. L'entraînement du modèle sur 18 mois a consommé 281 000 m^3 d'eau (l'équivalent de 112 piscines olympiques) et généré 20 400 tonnes de CO_2 (l'empreinte annuelle de 2 800 Français). Même cette étude pionnière reste imparfaite : le bilan environnemental des puces GPU n'est pas encore suffisamment documenté.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

BIAIS DANS LES DONNÉES D'ENTRAÎNEMENT

Yasmin Dwiputri & Data Hazards Project / Better Images of AI / Safety Precautions / CC-BY 4.0

Les données d'entraînement devraient refléter le monde et sa diversité. Mais elles viennent du web et des réseaux sociaux, où circulent des propos sexistes, racistes ou complotistes. On parle de « biais » quand l'IA reprend ces préjugés ou laisse de côté certaines cultures.

ALLER PLUS LOIN

En août 2026, france info a soumis à Gemini et ChatGPT la même phrase, « Je suis seule avec un… », en changeant seulement la nationalité. Avec un Suisse, Gemini y voit une occasion d'échanger et de passer un bon moment. Avec un Syrien, elle renvoie vers les numéros d'urgence. Sur les 15 nationalités non occidentales testées avec ChatGPT, 12 ont été traitées comme un danger possible.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

DONNÉES D'ENTRAÎNEMENT « SYNTHÉTIQUES »

Jamillah Knowles & We and AI / Better Images of AI / People and Ivory Tower AI 2 / CC-BY 4.0

Sur le web, on trouve des connaissances mais les entreprises d'IA cherchent toujours plus de données pour alimenter leurs modèles. Les chercheuses et chercheurs fabriquent parfois des données avec d'autres IA. Le risque : à trop s'entraîner sur ce qu'il a lui-même produit, un modèle peut se dégrader.

★★★

ALLER PLUS LOIN

En janvier 2025, OpenAI accuse l'entreprise chinoise DeepSeek d'avoir utilisé les réponses de ChatGPT pour entraîner son modèle concurrent. Cette technique, la distillation, s'appuie sur des données « synthétiques » : une IA sert de source pour en entraîner une autre. Paradoxalement, OpenAI était elle-même poursuivie par le New York Times pour usage non autorisé de contenus journalistiques.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

RESPECT DES DROITS D'AUTEUR

Anne Fehres and Luke Conroy & AI4Media / Better Images of AI / Humans Do The Heavy Data Lifting /CC-BY 4.0

Sans accord des créatrices et créateurs, il est interdit d'utiliser leurs œuvres et productions protégées par le droit d'auteur. Pourtant les entreprises d'IA s'en servent pour s'entraîner, invoquant le « fair use », règle américaine contestée en droit français pour un usage commercial.

ALLER PLUS LOIN

En 2026, Mediapart a testé le modèle français Mistral Large 3 en lui demandant de générer successivement les paragraphes d'œuvres protégées par le droit d'auteur. En lui donnant le paragraphe précédent de l'ouvrage, le modèle a restitué 58 % du texte original du Petit Prince, 35% de Harry Potter et 25% du Hobbit. Un tel taux indique que le modèle a été entraîné sur l'œuvre entière, sans autorisation.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

OPACITÉ DES DONNÉES D'ENTRAÎNEMENT

Alexa Steinbrück / Better Images of AI / Explainable AI / CC-BY 4.0

Difficile de comprendre les réponses d'une IA sans savoir sur quelles données elle a été entraînée. Les entreprises gardent ces informations secrètes, par peur de procès sur le droit d'auteur et pour protéger leurs méthodes. Une loi européenne les oblige désormais à en publier un résumé.

★★

ALLER PLUS LOIN

Depuis août 2025, l'AI Act oblige les fournisseurs de grands modèles d'IA à publier un résumé de leurs données d'entraînement. L'objectif : permettre aux autrices, auteurs, artistes et autres ayants droit de savoir si leurs œuvres ont été utilisées sans autorisation. En pratique, les géants comme OpenAI, Google ou Anthropic n'ont encore rien publié. Seules quelques entreprises de petite taille ont joué le jeu. Des sanctions pourraient s'appliquer prochainement pour les sociétés qui ne publient pas ces informations.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

DÉCOUPAGE DU TEXTE EN PETITES UNITÉS

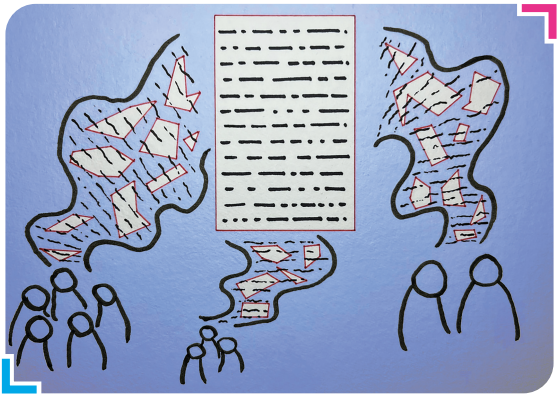

Yasmine Boudiaf & LOTI / Better Images of AI / Data Processing / CC-BY 4.0

Avant l'entraînement, le texte est coupé en « tokens », des morceaux souvent plus petits qu'un mot. Par exemple, « Voici quelques éléments » peut donner : « Vo », « ici », « quelques », « él », « éments ». Le modèle ne lit pas des mots, il traite des fragments.

ALLER PLUS LOIN

Les modèles sont optimisés pour les langues les plus utilisées dans le monde, à commencer par l'anglais. À contenu égal, certaines langues demandent bien plus de tokens que d'autres, donc plus de calcul et d'argent. Certaines équipes de recherche ont donné le nom de « taxe token » pour désigner le surcoût à payer dans certaines langues. Pour un même texte, il faut déjà 20 à 30 % de tokens en plus en français qu'en anglais, et jusqu'à 10 fois plus dans des langues peu présentes dans les données, comme le wolof (Sénégal).

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

ANNOTATION DES DONNÉES

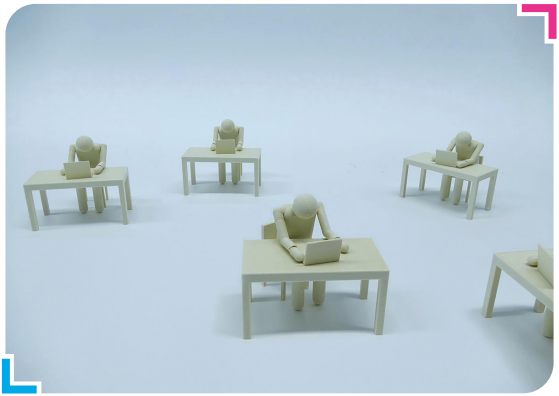

Max Gruber / Better Images of AI / Clickworker Abyss / CC-BY 4.0

Avant l'entraînement, les données doivent être annotées : des personnes lisent des textes et signalent ce qui est faux, haineux ou violent. Pour que ça leur coûte moins cher, les entreprises confient ce travail à des personnes dans des pays où les salaires sont bas et les conditions souvent dures.

ALLER PLUS LOIN

A Madagascar ou au Kenya, des étiqueteuses et étiqueteurs de données reçoivent des conversations clients non triées et doivent identifier le ton émotionnel (positif, négatif, neutre) pour entraîner des modèles de traitement du langage naturel. Ils et elles sont rémunérés à la tâche, paient leur matériel. Si elles ou ils se plaignent des conditions, les tâches à effectuer sont proposées à d'autres personnes.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

FILTRAGE DU CONTENU INAPPROPRIÉ

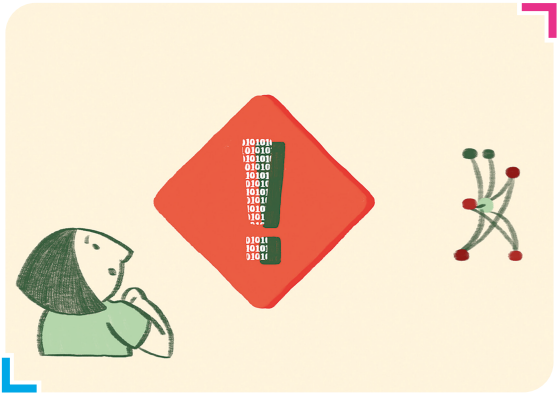

Yasmin Dwiputri & Data Hazards Project / Better Images of AI / Managing Data Hazards / CC-BY 4.0

Les données d'entraînement viennent du web et des réseaux sociaux. Elles contiennent des erreurs, des préjugés et des appels à la haine. Elles sont filtrées pour que le modèle ne les répète pas. L'industrie parle de « dé-biaiser », comme s'il existait des données neutres.

ALLER PLUS LOIN

Le Washington Post a analysé les données d'entraînement utilisées par Google. Elles avaient été filtrées à partir d'une liste de 402 mots jugés obscènes. Des termes utilisés dans les communautés LGBTQIA+ ont été effacés, comme l'adjectif « homoérotique », employé en critique littéraire et artistique pour décrire une tension sexuelle sans acte sexuel. Dans le même temps, « swastika » (croix gammée), présent sur cette liste, apparaît 72 000 fois dans les données finales.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

SÉLECTION DES CONTENUS DE QUALITÉ

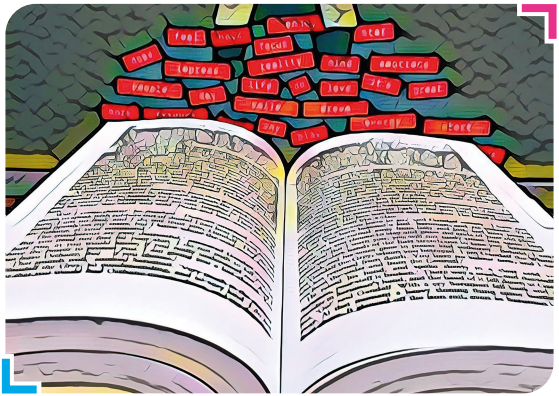

Teresa Berndtsson / Better Images of AI / Letter Word Text Taxonomy / CC-BY 4.0

On n'entraîne pas les modèles d'IA sur tout le web : on n'en garde qu'une petite partie jugée de « qualité » (bien écrite, sans fautes). Ces critères sont fixés par des ingénieurs occidentaux, diplômés et bien payés. Décider ce qui est un « bon » texte reflète donc leur culture.

ALLER PLUS LOIN

Reddit, énorme forum en ligne, a été utilisé pour filtrer les données d'entraînement. « Les usagers » y votent pour des messages ou des liens. Ceux recevant beaucoup de votes sont jugés de qualité. En 2023, Reddit a rendu payant l'exploitation de ces votes et les messages du forum. Des milliers d'usagers et usagères se sont mis alors en grève pour protester contre la marchandisation de leur travail.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

ENTRAINEMENT D'UN RÉSEAU DE NEURONES ARTIFICIELS

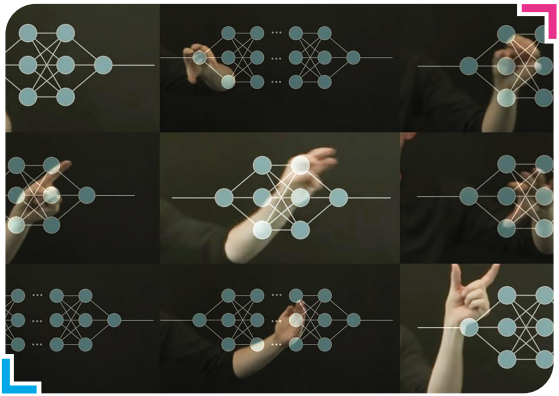

Alexa Steinbrück / Better Images of AI / Explainable AI / CC-BY 4.0

Un réseau de neurones s'inspire du cerveau humain. Comme dans le cerveau, chaque unité reçoit des informations, les traite, puis les transmet aux suivantes. Au fil de l'entraînement, les liens entre ces unités se renforcent quand les mêmes informations reviennent souvent.

ALLER PLUS LOIN

En novembre 2016, Google a basculé son service de traduction vers des réseaux de neurones. L'ancien système découpait les phrases en segments et cherchait des équivalents statistiques. Le nouveau traduit des phrases entières en apprenant à partir de millions d'exemples. Google parlait d'un bond en avant supérieur aux dix années précédentes réunies.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

REGROUPEMENT DES MOTS SIMILAIRES ENTRE EUX

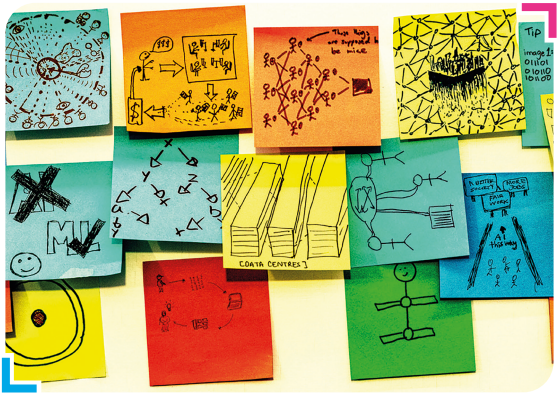

Rick Payne and team / Better Images of AI / Ai is... Banner / CC-BY 4.0

Le modèle range chaque mot à une position, calculée d'après les mots qui l'entourent souvent. Les mots employés dans les mêmes contextes se retrouvent voisins. « Maison » est proche de « habitation ». « Charme » est proche à la fois de « séduction » et de « magie ».

★★★

ALLER PLUS LOIN

En 2024, Sara Sterlie, une étudiante de l'Université technique du Danemark a demandé à ChatGPT d'attribuer des métiers à des prénoms masculins et féminins. Les femmes obtiennent plus souvent infirmière, styliste, graphiste. Les hommes sont identifiés comme ingénieur, architecte, cadre dirigeant. Les biais des textes d'entraînement s'encodent dans les coordonnées mathématiques de chaque mot dans le modèle.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

LECTURE ATTENTIVE DU TEXTE PAR LA MACHINE

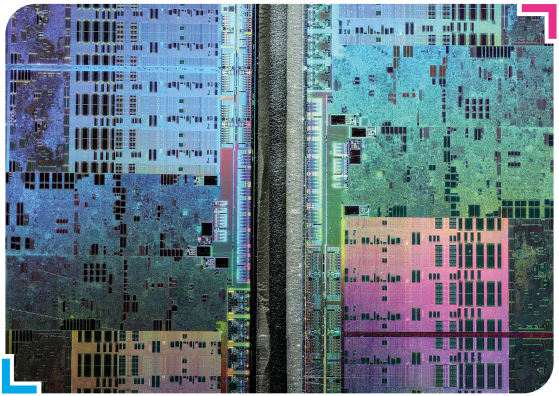

Fritzchens Fritz / Better Images of AI / GPU shot etched 5 / CC-BY 4.0

Depuis 2017, un système appelé « transformer » a changé l'analyse de texte. Avant, chaque mot était traité isolément. Aujourd'hui, le modèle tient compte du contexte de chaque mot. Par exemple, dans « le chat a poursuivi le rat, puis il l'a mangé », le modèle relie « il » au chat.

★★★

ALLER PLUS LOIN

En juin 2017, huit chercheuses et chercheurs de Google publient l'article «Attention is All You Need», qui présente l'architecture Transformer (c'est le "T" de ChatGPT). Google diffuse aussi son code librement. N'importe quelle entreprise peut alors réutiliser cette recherche sans payer de licence. OpenAI, Meta ou Anthropic s'appuient ainsi sur cette architecture ouverte pour développer leurs propres modèles.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

SURVEILLANCE ET TEST DU MODÈLE

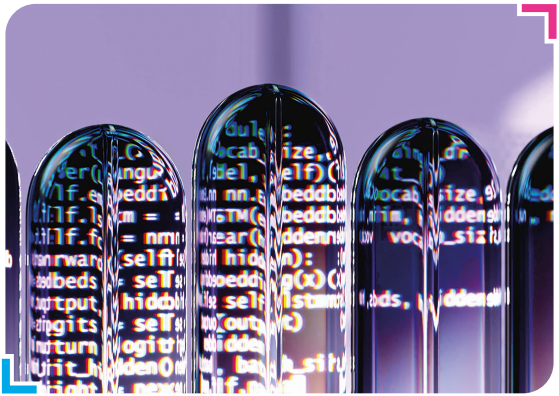

Wes Cockx & Google DeepMind / Better Images of AI / AI large language models / CC-BY 4.0

Pendant l'entraînement, on surveille les progrès. On met de côté 10 à 20 % des données, sans jamais les montrer au modèle. On teste alors s'il sait les prédire. Quand les résultats ne s'améliorent plus, on arrête l'entraînement.

ALLER PLUS LOIN

« Humanity's Last Exam » (le dernier examen de l'humanité) réunit 2 500 questions, chacune écrite par un ou une spécialiste d'un domaine différent. Introuvables en ligne, ces questions testent le modèle avec des questions jamais vues. En 2024, GPT-4o obtenait 2,7 % de bonnes réponses. Fin 2025, Gemini 3 Pro atteint environ 37 %. Les spécialités sont si variées qu'une personne seule, même experte d'un domaine, ne peut répondre à tout le test.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

AMÉLIORATION DES RÉPONSES PAR DES HUMAINS

Nacho Kamenov & Humans in the Loop / Better Images of AI / Data annotators discussing the correctlabeling of a dataset / CC-BY 4.0

Après l'entraînement, un modèle donne encore des réponses fausses, incohérentes ou dangereuses. Des humains les évaluent pour l'améliorer. Le modèle s'ajuste par un système de points : une bonne réponse rapporte un bonus. Les usagères et usagers y participent en notant les réponses.

ALLER PLUS LOIN

En janvier 2025, l'IA française Lucie a été mise en ligne... et débranchée trois jours plus tard face à une polémique grandissante. Elle affirmait que les œufs de poule sont produits par des vaches, échouait à résoudre des calculs simples. Lucie était un modèle entraîné sans avoir été «instruit» ni évalué par des personnes. Sans ce travail de renforcement, le modèle était inutilisable.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

AJUSTEMENT DE MODÈLES PRÉ-ENTRAÎNÉS

Yasmin Dwiputri & Data Hazards Project / Better Images of AI / AI across industries. / CC-BY 4.0

Entraîner un bon modèle depuis zéro est long et très cher. Des entreprises comme Google, Meta ou Mistral publient donc des modèles déjà entraînés. Ces modèles peuvent être adaptés à un besoin précis (droit, médecine, service client) avec quelques milliers d'exemples, sans refaire un entraînement complet.

★★

ALLER PLUS LOIN

Des entreprises comme Mistral AI ou Meta publient certains modèles qui sont librement modifiables et utilisables, y compris pour des usages commerciaux. Ces modèles ouverts attirent une clientèle dont une partie paiera pour les offres payantes. Mais les données qui ont entraîné ces modèles restent secrètes. Ces modèles sont également qualifiés de "semi ouverts" s'il n'est pas possible d'inspecter les données d'entraînement.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

MESURE ET COMPARAISON DES PERFORMANCES DU MODÈLE

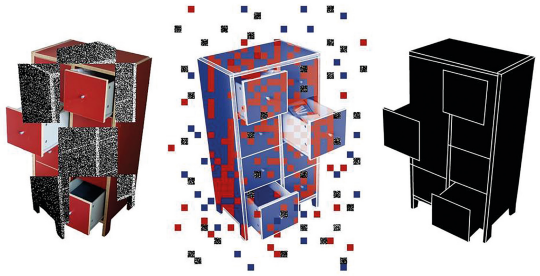

Anton Grabolle / Better Images of AI / Classification Cupboard / CC-BY 4.0

Pour améliorer le modèle, l'industrie l'évalue avec des tests standardisés, appelés « benchmarks ». Les résultats sont mesurés sur des tâches précises : exactitude, tri de textes, logique… Ces scores guident les réglages suivants et servent à comparer les modèles.

★★★

ALLER PLUS LOIN

Ces tests posent problème. Ils portent presque toujours sur l'anglais. Selon le ministère de la Culture, un grand jeu de données qui sert de référence pour évaluer de nombreux modèles d'intelligence artificielle, ne compte que 1,5 % de conversations en français. Le ministère a créé Compar:IA en réponse, un site ouvert à toutes et tous pour comparer et noter les réponses de plusieurs IA, pour créer des données en français et mieux évaluer les modèles.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

MANQUE DE DIVERSITÉ LINGUISTIQUE

Max Gruber / Better Images of AI / Banana / Plant / Flask / CC-BY 4.0

L'entraînement des IA repose surtout sur des contenus en anglais. Les modèles fonctionnent donc moins bien dans les autres langues. Après l'entraînement, des personnes ajustent les réponses du modèle pour progresser dans d'autres langues. Mais ce travail reste limité et l'écart de performance avec l'anglais persiste.

ALLER PLUS LOIN

En 2024, le projet Aya a réuni 3 000 chercheuses et chercheurs de 119 pays pour améliorer les réponses d'un modèle dans 101 langues, dont beaucoup sont peu présentes en ligne comme le wolof. Chaque contribution était relue par d'autres personnes du projet. Mais la tâche reste immense : près de 80 % des langues du monde n'ont quasiment pas de textes disponibles.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

CONFIDENTIALITÉ DES ÉCHANGES

Yutong Liu & Kingston School of Art / Better Images of AI / Talking to AI 2.0 / CC-BY 4.0

Par défaut, les modèles d'IA réutilisent vos conversations pour s'entraîner. Celles-ci peuvent contenir des informations sensibles ou confidentielles (santé, secrets d'entreprise). Dans l'Union européenne, la loi permet de le refuser, mais l'option est cachée et peu de gens l'activent.

ALLER PLUS LOIN

En 2023, l'Italie a suspendu l'accès à ChatGPT pendant quelques semaines, après une fuite de données et des doutes sur le respect de la vie privée. Suite à l'enquête qui a abouti en décembre 2024, l'autorité italienne a condamné OpenAI à 15 millions d'euros pour avoir utilisé les données des utilisateurs pour entraîner le modèle sans base légale suffisante.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

OMNIPRÉSENCE DE L'IA DANS LES USAGES

Reihaneh Golpayegani & The Bigger Picture / Better Images of AI / A Corner Of The History / CC-BY4.0

Les IA sont de plus en plus présentes dans nos messageries, moteurs de recherche et outils du quotidien, souvent sans qu'on le remarque. Reliées à internet, avec un objectif, elles deviennent des « agents » : elles planifient et agissent seules jusqu'à la fin de la tâche.

ALLER PLUS LOIN

Des outils comme Claude Code ou ChatGPT Codex permettent de déléguer l'écriture de code à un agent IA. Cet usage devient de plus en plus répandu parmi les développeuses et développeurs. En janvier 2026, un développeur a tenté d'en estimer la consommation électrique car les entreprises ne publient pas ces données. Ses calculs montrent qu'une session de codage avec un agent consomme 138 fois plus qu'une requête classique à un chatbot.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

CONSOMMATION ÉLECTRIQUE À CHAQUE USAGE

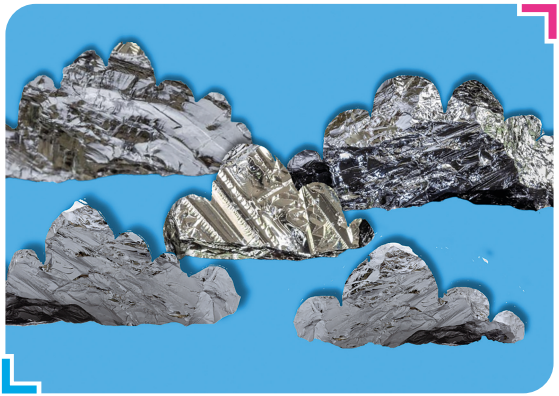

Catherine Breslin & Tania Duarte / Better Images of AI / AI silicon clouds collage / CC-BY 4.0

Chaque usage de l'IA consomme de l'électricité. Cette consommation dépend de la taille du modèle et de la longueur de la conversation. Certains modèles sont conçus pour consommer moins. Mais ces économies ne compensent pas l'explosion des usages : c'est « l'effet rebond ».

ALLER PLUS LOIN

Certains modèles produisent des milliers de fragments de texte avant de donner leur réponse. Ce « raisonnement » améliore la qualité en détaillant les étapes jusqu'au résultat mais fait fortement grimper la consommation d'électricité. En décembre 2025, le projet AI Energy Score a comparé la consommation de 40 modèles avec et sans raisonnement activé. Pour certains modèles comme ceux de DeepSeek, l'activation du mode raisonnement multipliait la consommation électrique par six.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA

INVENTION D'INFORMATIONS

Amritha R Warrier & AI4Media / Better Images of AI / error cannot generate / CC-BY 4.0

Les systèmes d'IA générative sont programmés pour toujours répondre. Ils calculent la suite de mots la plus probable. Leurs réponses paraissent crédibles, mais elles peuvent être fausses. Ces erreurs sont souvent qualifiées d'« hallucinations » quand le modèle invente des informations.

★★★

ALLER PLUS LOIN

Le terme « hallucination » est controversé car il suggère que l'IA aurait une conscience ou des perceptions altérées, alors qu'il s'agit d'erreurs statistiques de prédiction. Par exemple, la chercheuse en éthique Margaret Mitchell a demandé à Gemini (Google) «combien de présidents musulmans avaient eu les Etats-Unis ?» Gemini a répondu un, citant Barack Obama qui est chrétien protestant.

Nantes Métropole DATACTIVIST LA BOÎTE NOIRE DE L'IA

en collaboration avec le réseau de la médiation numérique de Nantes Métropole

CC BY SA